Procesamiento Local de Informes Médicos con Llama 3.2 3B

Resumen

El presente estudio evalúa el diseño, rendimiento y validez analítica de un pipeline de Inteligencia Artificial (IA) local implementado para la extracción y estructuración automatizada de datos a partir de **410.483 informes de diagnóstico por imagen** almacenados en la plataforma DiconLine. Por motivos estrictos de confidencialidad y gobernanza, se desplegó el modelo de lenguaje de gran escala **Meta Llama 3.2 (3B parámetros)** de forma puramente local mediante el ecosistema **Ollama**. La metodología contempló una fase de limpieza radical de código HTML libre (*resto_html*), procesamiento en paralelo por hilos y un exhaustivo análisis estadístico inferencial (Chi-cuadrado χ^2, ANOVA de un factor y Welch) sobre una submuestra analítica de **99.471 registros válidos**.

Los resultados técnicos demuestran que el sistema procesó con éxito el **25,3% del universo total (103.712 informes)**, alcanzando una tasa de eficacia estructural del **95,6% (99.134)** en la submuestra analizada. Se identificó un cuello de botella crítico de origen operativo: el campo *edad* registró un déficit de completitud del **20,9%**, causado por la heterogeneidad de formatos manuales. El análisis inferencial confirmó una asociación estadística monumental entre las modalidades de estudio y los grupos etarios ($\chi^2 = 30.652{,}4$, $p < 0{,}0001$), así como disparidades significativas en la edad media global según el sexo ($p < 0{,}0001$). Se concluye que el procesamiento local masivo mediante LLMs ligeros es viable y seguro, recomendando la ejecución de scripts homogeneizadores de datos y el escalonamiento de modelos jerárquicos (Llama 3.1 8B) para rescatar el subconjunto de informes con fallos estructurales.

Introducción

En los entornos intrahospitalarios modernos, la plataforma de imágenes médicas DiconLine almacena en formato HTML los reportes generados por los especialistas, los cuales albergan información demográfica crucial y descripciones detalladas de modalidades, estudios, hallazgos, resultados y conclusiones. No obstante, estos reportes presentan una serie de problemas técnicos y sintácticos que dificultan su explotación analítica directa y su conversión en tablas de datos relacionales: la persistencia de etiquetas de marcado complejas, la omisión de términos estándar, el empleo generalizado de sinónimos clínicos heterogéneos, palabras mal escritas o truncadas, y una marcada disparidad en la densidad de las conclusiones por informe.

Para transformar este volumen masivo de datos no estructurados en conocimiento útil sin vulnerar la confidencialidad del paciente, se descartó el uso de APIs comerciales en la nube. Este trabajo plantea un marco metodológico enfocado en resolver estos desafíos mediante el despliegue local de Modelos de Lenguaje de Gran Escala (LLMs) de última generación. El objetivo central es auditar el rendimiento técnico del pipeline de procesamiento masivo, cuantificar las causas de error del modelo artificial, mapear la completitud de las variables críticas extraídas e interpretar de manera inferencial las tendencias clínicas y demográficas subyacentes en el dataset estructurado.

Metodología

- **Diseño de la Investigación:** Estudio analítico, descriptivo y transversal de auditoría de sistemas de datos sanitarios e inferencia bioestadística de registros clínicos automatizados.
- **Descripción de los Registros:** El universo general del estudio comprende un total de **410.483 informes clínicos**. El análisis detallado se ejecutó sobre la submuestra de **99.471 registros válidos** correspondientes a diversas modalidades médicas que completaron el flujo de datos.
- **Herramientas y Entorno Tecnológico:**
    - **Procesamiento Local:** Uso del gestor de código abierto **Ollama** ejecutando el modelo **Meta Llama 3.2 (3B)** cuantizado a 4 bits (~2 GB de peso) de manera física local en un ordenador personal para garantizar la privacidad. Se configuró un prompt de sistema determinista, temperatura de **0.0** (creatividad cero), y un tamaño de contexto optimizado mediante `num_ctx`.
    - **Pipeline de Datos:** Desarrollo de un script en Python que realiza un pre-mapeo demográfico estándar, una limpieza radical de HTML mediante *BeautifulSoup* e inyección paralela concurrente de registros a través de **4 hilos** (`NUM_HILOS = 4`) en bloques manejables de memoria de 500 en 500 registros (`TAMAÑO_BLOQUE_MEMORIA = 500`) hacia una base de datos local NoSQL **MongoDB** (*sistema_medico_procesado*).
- **Técnicas de Análisis Estadístico Inferencial:** Implementación de contrastes de hipótesis parametrizados con un nivel de significación $\alpha = 0,05$ en MongoDB y Python:
    - Prueba de Chi-cuadrado (χ^2) asociada a la V de Cramér para determinar la independencia entre variables categóricas (Estudio y Grupo de Edad).
    - Análisis de residuos ajustados de Pearson ($|z| > 2$) para geolocalizar sobrefrecuencias locales en matrices de confusión.
    - Contraste ANOVA de un factor y prueba robusta de Welch con corrección secuencial de Holm para comparaciones múltiples de tasas y medias demográficas.

Resultados

1. Estado General de Procesamiento

- **Avance del Procesamiento:** El pipeline ha procesado con éxito el **25,3% (103.712 informes)** del total de la base de datos de DiconLine, manteniendo un volumen pendiente de **306.771 informes (74,7%)**.
- **Métricas de Éxito Técnico:** De la fracción enviada a Ollama, el **95,6% (99.134 informes)** finalizó correctamente. Únicamente el **4,4% (4.578 informes)** exhibió un flag de error estructural (`tiene_problema_estructural: True`).
- **Distribución de Estados Administrativos (*Status*):** Predominancia de informes en estado DRAFT (**66,1%**), seguidos de COMPLETED (**33,8%**) y CANCELLED (**0,1%**).



2. Análisis de Errores y Cuellos de Botella Técnicos

- **Motivos de Fallo de la IA:** Se dividen de forma casi equitativa entre un error en la estructura jerárquica o JSON corrupto (**52,5%**) y un HTML vacío u omitido desde el origen (**47,5%**).
- **Tasa de Problemas según Tamaño del HTML:** Se evidenció una distribución geométrica en "U". Los documentos ultra cortos (<500 caracteres) reportaron un **27,5% de error** (n = 924) por falta de contenido. El tramo óptimo (500 a 8.000 caracteres) registró tasas mínimas de fallo (entre **0,6% y 4,7%**). Los documentos macro extensos (>16.000 caracteres) colapsaron con un **100,0% de error** (n = 2) debido al desborde físico de la ventana de contexto fijada en `num_ctx: 1024`.
- **Completitud de Campos Clave:** Los atributos básicos extraídos por Python (*resto_html*, *sexo* y *status*) alcanzaron un **100,0% de llenado**. La extracción semántica de *modalidad* por la IA logró un **94,6%**, mientras que el atributo *edad* se identificó como el cuello de botella más severo del sistema con apenas un **79,1% de completitud**.

3. Caracterización Demográfica y Perfil Clínico

- **Demografía Básica:** Prevalencia de registros de sexo masculino (**66,3%**) frente a femenino (**33,7%**). La edad media global de los pacientes evaluados se fijó en **46,9 años**, siendo el grupo etario predominante el de 45-59 años (**27,7%**).
- **Modalidades Médicas:** Las Radiografías lideran la actividad (**44,9%**), seguidas de la Tomografía Computarizada (**25,4%**) y la Resonancia Magnética (**21,1%**). Un análisis de Pareto demostró que **solo 18 estudios únicos acumulan el 80% de toda la actividad** (liderado por Radiografía de Tórax y Mamografía).
- **Clasificación Clínica Heurística:** El **18,1%** de los estudios se clasificó bajo el diccionario de palabras clave como RELEVANTE (patológico activo), el **24,3%** como NORMAL y el **53,6%** correspondió a OTROS HALLAZGOS.

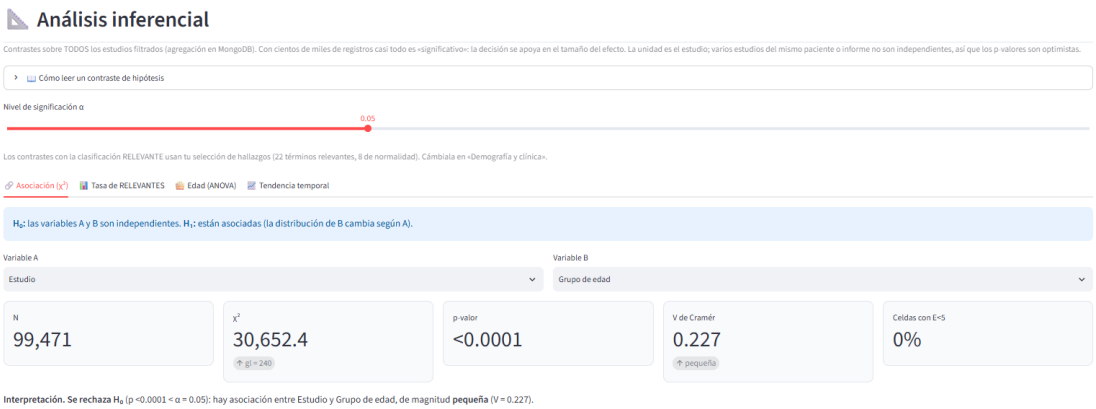
4. Análisis Inferencial y Pruebas de Hipótesis

Prueba de Asociación χ^2: Estudio (Modalidad) × Grupo de Edad

- **Estadísticos:** N = 99.471 | χ^2 = 30.652,4 | gl = 240 | p-valor < 0,0001 | V de Cramér = 0,227 | Celdas con E < 5 = 0%.
- **Interpretación:** Se rechaza categóricamente la hipótesis nula de independencia. El mapeo de residuos ajustados develó que las Mamografías presentan una sobrefrecuencia extrema (**z = +72.9**) exclusivamente en el tramo de 45-59 años.
- **Mapeo de Datos Perdidos:** La columna "SIN DATO" de edad correlaciona de forma intensa con Radiografía de Columna Dorsal (**z = +39.2**), Radiografía de Columna Cervical (**z = +37.7**) y Radiografía de Columna Lumbar (**z = +31.2**), demostrando un fallo originado por las plantillas textuales de origen en dichos estudios.

Tasa de Informes RELEVANTES por Grupo de Edad (Corrección de Holm)

- **Métricas:** Tasa global basal = 18,13% (6 de los 7 segmentos analizados difieren significativamente de la media).
- **Interpretación:** El pico máximo de relevancia patológica se concentra en el grupo de 00-17 años con un **22,2%** e identificando un Odds Ratio (OR) de **1.33**. El tramo con menor tasa patológica fue "SIN DATO" de edad con solo **12,8%** (OR = 0.58).



Comparación de Edad Media según el Sexo (ANOVA / Welch)

- **Métricas:** Grupos = 3 | Muestra Utilizable = **70.965 registros con edad y sexo simultáneos** | ANOVA F = 804,1 (p < 0,0001) | Welch F = 834,7 (p < 0,0001) | Tamaño del efecto (η^2) = 0,022.
- **Interpretación:** Se rechaza la hipótesis nula de igualdad de medias. El sexo femenino posee una edad media significativamente más alta, concentrada entre los **47 y 48 años**, mientras que el sexo masculino promedia edades menores, situadas en el intervalo de los **34 a 35 años**. Los registros "No Especificado" promedian edades jóvenes (25 a 35 años) con una barra de error más ancha.

Discusión

Los resultados técnicos demuestran que la implementación de un pipeline estructurador basado en un modelo local ligero (Llama 3.2 3B) constituye una solución altamente viable para la gestión de Big Data clínico, ostentando un **95,6% de efectividad de parseo** y preservando la privacidad absoluta de los registros. No obstante, el análisis de fallos según el tamaño del HTML evidencia las limitaciones empíricas de la infraestructura. El colapso del rendimiento en textos extensos (>16k caracteres; 100% de error) coincide con el truncamiento físico de la ventana de contexto fijada por `num_ctx` en la llamada a Ollama, lo que provoca que la IA sea incapaz de cerrar las llaves sintácticas del JSON estructurado.

Desde una dimensión analítica, el déficit del **20,9% de completitud en el campo edad** representa un sesgo no aleatorio (*Missing Not At Random*, MNAR). El mapa de calor inferencial de residuos ajustados demostró que esta ausencia de información se agrupa de manera sistemática en estudios radiológicos específicos de columna vertebral (Dorsal 66%, Cervical 48%, Lumbar 45%). Esto confirma que las plantillas estructuradas de transcripción médica convencionales en dichos exámenes introducen vicios de formato que rompen la expresión regular del modelo.

A nivel clínico, la fuerte asociación inferencial ratifica que el set de datos resultante refleja fidedignamente los patrones de prescripción epidemiológica internacionales (como el cribado mamario en la quinta década de la vida). El hallazgo de que el segmento infantil (00-17 años) posea un Odds Ratio de positividad patológica de **1,33** amplía lo descrito por la literatura en gestión clínica: en pediatría se minimiza el uso de radiación ionizante por control rutinario; si se prescribe una imagenología, la probabilidad pre-test de una patología aguda (fracturas, neumonías) es inherentemente mayor.

Conclusión

Este estudio ha auditado con éxito el estado del procesamiento por IA de **410.483 informes clínicos**, revelando que el despliegue local mediante Ollama y Python es una alternativa costo-eficiente, robusta e inmune a filtraciones externas para procesar el texto libre de la plataforma DiconLine. Sin embargo, la presencia de un déficit del **20,9% en la extracción de edad** compromete la precisión epidemiológica del dataset si no se aplican medidas correctivas inmediatas. Las pruebas inferenciales probaron que las omisiones obedecen a un patrón sistemático vinculado al tipo de examen y no al azar.

Recomendaciones

1. **Revisar la información sin datos:** Es imperativo revisar que se puede recuperar ese ~21% de la edad de registros faltantes, el bloque "SIN DATO".
2. **Implementar una Estrategia de Modelos Escalonados (Cascading LLMs):** Para el subbloque del **4,4% (4.578 informes)** marcado con problemas estructurales o JSON corrupto, se recomienda configurar un re-enrutamiento automático hacia el modelo **Llama 3.1 (8B)**. Al ser un volumen acotado de documentos, el hardware local del ordenador no se verá desbordado y se aprovechará la mayor capacidad del modelo de 8B para interpretar textos largos y seguir instrucciones complejas.
3. **Procesar por Temporalidad y Validar en Origen:** Priorizar el procesamiento del 74,7% de informes pendientes siguiendo un orden cronológico vinculado a su fecha de creación y última actualización, cruzándolo con el *Status* administrativo (Draft vs. Completed). Asimismo, se sugiere implementar validaciones obligatorias en el software de admisión hospitalaria (RIS) para impedir la inserción de formatos de edad anómalos antes de su almacenamiento centralizado.

Referencias bibliográficas

- Miot, H. A. (2011). Chi-square test in clinical and epidemiological studies. *Jornal Brasileiro de Dermatologia*, 86(2), 383-385.
- Ollama Open Source Project. (2024). *Ollama: Streamline large language model deployment locally*. GitHub Repository. github.com